


# AEM4L2 | Introducción a Audio Pipelines



De la señal al significado: Diseñando y evaluando sistemas ASR robustos

## De la señal al significado: Diseñando y evaluando sistemas ASR robustos




# La diferencia entre una interacción fluida y un fallo frustrante

Transformar lenguaje hablado en texto preciso es un desafío técnico complejo. En contextos médicos o legales, una sola palabra mal interpretada altera el resultado. El éxito depende enteramente del diseño del pipeline acústico.




# La transcripción es solo el primer paso

Las empresas invierten en ASR para extraer datos accionables. Cualquier error sistemático en esta base erosiona directamente la confianza del usuario y la viabilidad del producto.



# La anatomía de un pipeline de audio a texto

Cada etapa moldea la confiabilidad de la máquina. Este flujo es secuencial: un error en las primeras etapas se amplifica en las últimas.



# El efecto dominó de los errores de audio

Los errores tempranos se propagan y arruinan el resultado final. Si el modelo recibe texto corrupto, fabricará detalles u omitirá información clave.



Regla práctica: Cambiar el LLM no arregla un transcript roto.  
(Garbage in, garbage out).

# Tokenización: el motor invisible del ASR

¿Por qué algunos modelos se “comen” palabras o tropiezan con nombres propios? Es el proceso de dividir el audio en unidades discretas, decidiendo qué ‘átomos’ lingüísticos el modelo puede escuchar.

## Segmentación Textual

E S T O E S U N E J E M P L O

[ESTO] [ES] [UN] [EJEMPLO]

## Segmentación de Audio



# Encontrando la zona ideal de tokenización

El diseño del tokenizer es un delicado equilibrio entre maximizar la cobertura del lenguaje y minimizar los errores de predicción.

## Nivel de Carácter

- Flexibilidad: Alta
- Vocabulario: Pequeño
- Eficiencia: Baja

**Diagnóstico:** Propenso a typos, requiere demasiados pasos computacionales.

## Nivel de Palabra

- Flexibilidad: Baja
- Vocabulario: Enorme
- Eficiencia: Alta

**Diagnóstico:** Falla catastróficamente con palabras nuevas ([UNK]).

## La Zona Ricitos de Oro

## Nivel de Sub-palabra


- Flexibilidad: Alta
- Vocabulario: Optimizado
- Eficiencia: Alta

**Diagnóstico:** El balance perfecto. Construye significados desde partes conocidas.

# Cómo las subpalabras procesan términos desconocidos


Algoritmos como BPE o WordPiece evitan el temido error [UNK] construyendo palabras nuevas a partir de prefijos y sufijos conocidos. Si el vocabulario es muy pequeño, la fragmentación confundirá al LLM.

Diagrama de Descomposición de Subpalabras



# Evaluando la caja negra sin subjetividades

Para dejar de adivinar el origen de los errores, necesitamos métricas objetivas y reproducibles comparadas contra un **Ground Truth** verificado.



Evaluación Subjetiva / Confianza Baja

## Panel de Métricas de QA

QA Dashboard

Tasa de Error

Error: 4.2%

↓ 0.3%

Precisión: 95.8%

F1 Score: 0.94

WER: 2.1%

WER: 2.1%

WER: 0.94

Medición Objetiva / Rigor Matemático

# Diseño de Golden Validation Cases


Los Golden Cases son escenarios de referencia (Ground Truth). Aseguran que las métricas reflejen escenarios de producción reales, abarcando desde diálogos nítidos hasta audios con ruido y jerga médica.

## [Representativo]



Cubre escenarios típicos y distintos speakers.

## [Diverso]



Incluye edge cases, acentos marcados y jerga.

## [Alta Fidelidad]



Transcripciones humanas 100% precisas y revisadas.


## [Estable]



Reutilizable en el tiempo para trackear mejoras.

# Comprendiendo el Word Error Rate (WER)

WER es la métrica estándar. Mide la proporción de palabras incorrectas combinando Sustituciones (S), Eliminaciones (D) e Inserciones (I).




$$\text{Fórmula: WER} = (S + D + I) / N$$

$$\text{WER} = (0 + 1 + 0) / 7 = 14\%$$


# Diagnóstico del Word Error Rate

Conocer el porcentaje del WER es solo el comienzo; lo vital es entender el porqué detrás de cada fallo.



# Cómo la tokenización distorsiona las métricas

Un WER más bajo no siempre equivale a una mejor calidad final. Diferentes tokenizadores evalúan el mismo error de formas drásticamente distintas.




# Arquitecturas base: Transformers vs. Difusión



## [Transformers]

Intérpretes de una pasada

- Usan **autoatención** para entender **contexto global** simultáneamente.
- Ideales para **ASR**, traducción y resumen en **tiempo real**.



## [Diffusion Models]

Restauradores pacientes

- **Eliminan ruido** de forma **iterativa** y metódica.
- Ideales para generar y **restaurar** audio de **alta fidelidad** (TTS).

**Mini-caso:** Un call center usa **Transformers** para transcripción en tiempo real, y **Difusión** para restaurar grabaciones con estática.

# El plano maestro para la IA de audio

Construir un pipeline no termina en la transcripción; es orquestar sistemas capaces de escuchar, evaluar y mejorar con evidencia técnica.

